

Zlepšovanie presnosti neurónových modelov pomocou zašumených dát

Sofia Čorbová, Marek Bavoľár, Jakub Blizman, Matúš Konopinský, Miroslav Košarič

Abstract—V tejto práci sme sa venovali problematike zvýšenia robustnosti konvolučných neurónových sietí (CNN) voči obrazovému šumu. Analyzovali sme vplyv rôznych typov a intenzít šumu pridaných počas tréningového procesu na výkonnosť modelu pri klasifikácii obrázkov so šumom aj bez neho. V experimentoch sme použili predtrénovaný model ResNet34, ktorý sme adaptovali na úlohu klasifikácie 37 plemien psov a mačiek z datasetu Oxford-IIIT Pet. Implementovali sme pridávanie Gaussovho, Poissonovho a Salt-and-pepper šumu do obrázkov s rôznymi konfiguráciami a pravdepodobnosťou aplikácie. Trénovanie modelov prebiehalo počas 200 epoch s využitím stratégie Curriculum Learning v piatich fázach, kde sa postupne zavádzali rôzne typy šumu. Výkonnosť natrénovaných modelov bola následne hodnotená na vyhradenej testovacej množine dát, na ktorú bol aplikovaný rôzny typ a intenzita šumu. Výsledky ukázali, že modely trénované na čistých dátach dosahujú síce najlepšiu presnosť na čistej testovacej sade, avšak ich výkon dramaticky klesá pri zašumených vstupoch. Naopak, trénovanie so zašumenými dátami výrazne zlepšilo robustnosť modelov voči šumu v testovacích dátach, pričom optimálna intenzita a kombinácia šumu v tréningovej sade mala kľúčový vplyv na dosiahnutú klasifikačnú presnosť a F1 skóre, obzvlášť pri miernych úrovniach testovacieho šumu. Naše zistenia potvrdzujú, že systematická integrácia šumu do tréningového procesu je efektívnou metódou na zlepšenie schopnosti CNN modelov generalizovať a spoľahlivo fungovať v reálnom prostredí s variabilnou kvalitou obrazu.

Index Terms—Šum, konvolučné neurónové siete (CNN), zašumené dáta, robustnosť, klasifikácia.

I. ÚVOD

KONVENČNÉ prístupy k trénovaniu neurónových sietí spravidla predpokladajú prácu s vysoko kvalitnými, bezchybnými dátami. Avšak v reálnych aplikáciách modely musia čeliť rozličným formám šumu, ako sú kompresné artefakty, neostrosť, chyby senzorov alebo variabilné osvetlenie. Tieto faktory môžu zásadne ovplyvniť výkonnosť modelu, pokiaľ nebol navrhnutý tak, aby efektívne zvládol takéto rušivé javy.

Hlavným cieľom tohto článku je analyzovať dopad zašumených dát na klasifikačnú presnosť modelov a navrhnúť optimálny prístup pre systematickú integráciu zašumených dát do tréningového procesu. Pridanie šumu počas tréningu môže fungovať ako mechanizmus regularizácie, ktorý nielen zlepšuje schopnosť modelu generalizovať na neznáme dáta, ale aj zvyšuje jeho robustnosť voči nepredvídaným vstupným podmienkam.

V rámci tejto práce sa sústreďíme na integrovanie šumu do tréningových dát, charakterizáciu rôznych typov šumu a ich vplyvu na neurónové siete, kvantifikáciu účinnosti šumu ako regularizačného faktora v procese trénovania a porovnanie

výkonnosti modelov trénovaných na "ideálnych" dátach oproti modelom vystaveným šumovým perturbáciám.

Tento prístup má široké uplatnenie v oblasti počítačového videnia, vrátane úloh ako je klasifikácia objektov, detekcia anomálií či segmentácia obrazu. Prostredníctvom dôkladnej analýzy vplyvu šumu môžeme identifikovať optimálne stratégie na trénovanie modelov, ktoré sú odolnejšie voči variabilným podmienkam a vykazujú lepšiu schopnosť prispôbiť sa dynamike reálneho sveta.

II. PREHĽAD LITERATÚRY

V posledných rokoch sa venovala značná pozornosť vplyvu šumu na výkonnosť hlbokých neurónových sietí, najmä v oblasti konvolučných neurónových sietí (CNN) [11]. Štúdie naznačujú, že prítomnosť šumu v tréningových a testovacích dátach môže výrazne ovplyvniť klasifikačnú presnosť modelov, pričom niektoré formy šumu môžu mať výraznejší vplyv ako iné.

"Noise injection" [12], alebo injekcia šumu je technika, ktorá sa používa na zvýšenie robustnosti neurónových sietí tým, že sa do tréningových dát pridáva šum. Často sa používa napríklad Gaussov šum, ktorý má nastaviteľnú štandardnú odchýlku (σ), čím umožňuje regulovať intenzitu šumu. Tento typ šumu sa pridáva do obrazových dát pred ich vstupom do modelu.

Pridávanie šumu do obrazových dát má viaceré výhody. Augmentácia dát pridaním šumu pridáva väčšiu variabilitu do tréningových dát, čím zabraňuje modelu príliš sa prispôbiť špecifickému vzorom v dátach, čo slúži ako prevencia pretrénovania.

Modely trénované pomocou pridania šumu by teoreticky mali lepšie zvládať dáta s prirodzeným šumom, ako sú kompresné artefakty alebo rozmazané obrázky. Šum môže byť použitý na napodobnenie variácií v skutočných aplikáciách.

Pridanie šumu je možné použiť spolu s augmentačnými technikami, ako sú náhodné rotácie, zmeny kontrastu alebo jasu, aby sa zvýšila rozmanitosť tréningových dát. Okrem Gaussovho šumu sa používajú aj iné typy šumu, ako napríklad salt & pepper šum, ktorý simuluje vypadnuté pixely, alebo Poissonov šum. [1]

V práci [2] skúmali vplyv rôznych typov šumu na klasifikačnú presnosť CNN, pričom sa zamerali na datasety MNIST, CIFAR-10 a SVHN. Výsledky ukázali, že zašumené tréningové dáta môžu pomôcť modelom generalizovať na zašumených testovacích dátach, avšak súčasne môžu viesť k

zníženiu presnosti na čistých vstupoch. Autori sa venovali aj otázke, či pridanie šumu môže slúžiť ako regularizačný mechanizmus na zlepšenie robustnosti modelov voči variáciám v dátach. Ukázalo sa, že metódy na odšumenie, ako je Non-Local Means, môžu mať rôzny dopad na výkon modelov v závislosti od typu a intenzity šumu. Pri niektorých konfiguráciách odšumenia došlo k zlepšeniu presnosti, zatiaľ čo v iných prípadoch mohlo dôjsť k strate detailných črt v obraze, čo negatívne ovplyvnilo klasifikáciu. Štúdia taktiež ukázala, že kombinácia šumu s augmentačnými technikami, ako sú náhodné otočenia, zmeny jasu a kontrastu, môže pomôcť modelu lepšie zvládať zmeny v obraze a tým zvýšiť jeho schopnosť generalizácie.

V práci [3] analyzovali vplyv rôznych realistických modelov šumu na CNN a zahrnuli v experimentálnych nastaveniach Gaussov, Poissonov, speckle a salt & pepper šum. Ich výsledky ukázali, že zatiaľ čo Poissonov šum má minimálny vplyv na presnosť, speckle a salt & pepper šum môžu výrazne degradovať výkon CNN, a to najmä pri vyšších intenzitách šumu. Autori tiež preskúmali interakciu medzi šumom a osvetlením, pričom nižšie úrovne osvetlenia v kombinácii so šumom spôsobovali dramatické zníženie presnosti modelov. Okrem toho sa venovali otázke, či pridanie adaptívneho šumu, ktorý sa mení počas tréningu, môže pomôcť modelom lepšie sa prispôsobiť rôznym vstupným podmienkam. Výskum ukázal, že adaptívne riadený šum môže skutočne slúžiť ako regularizačný mechanizmus a znižovať tendenciu modelov k pretrénovaniu na špecifické dáta. Dôležitým zistením bolo aj to, že modely trénované na kombinácii čistých a zašumených dát vykazovali vyššiu robustnosť v porovnaní s modelmi trénovanými výlučne na zašumených dátach. To naznačuje, že optimálne nastavenie šumu a jeho kombinácia s čistými vstupmi môžu zohrávať kľúčovú úlohu pri vývoji odolných neurónových sietí.

V práci [5] analyzovali vplyv kvality obrazu na hlboké neurónové siete. Skúmali vplyv piatich hlavných typov degradácie obrazu: rozmazanie, šum, znížený kontrast, JPEG a JPEG2000 kompresiu. Ich experimenty ukázali, že neurónové siete sú obzvlášť citlivé na rozmazanie a šum, pričom pri vyšších úrovniach týchto skreslení dochádzalo k významnému poklesu presnosti modelov. Naopak, neurónové siete boli relatívne odolné voči kompresným artefaktom a zmenám kontrastu.

V rámci štúdie testovali výkonnosť štyroch CNN modelov (Caffe Reference, VGG-CNN-S, VGG-16 a GoogleNet) na modifikovanej verzii datasetu ImageNet 2012, kde boli aplikované rôzne úrovne degradácie obrazu. Výsledky ukázali, že najlepšie výsledky dosahoval model VGG-16, ktorý bol najodolnejší voči šumu a rozmazaniu. Zároveň bol tento model aj najväčší z testovaných modelov. Tieto zistenia zdôrazňujú dôležitosť použitia zašumených dát pri tréningu modelov, ak majú byť nasadené v reálnom prostredí, kde je kvalita vstupných obrázkov variabilná a často nie v ideálnej kvalite.

V práci [6] sa zamerali na dopad rôznych typov šumu na

úlohu klasifikácie obrazu. Do obrázkov pridávali Gaussov, Poissonov a Salt & Pepper šum. Štúdia sa odlišuje od predchádzajúcich tým, že testovala nielen vplyv šumu na výkonnosť modelov, ale aj to, do akej miery môžu metódy na odšumenie obrazu zmierniť tento dopad.

V rámci experimentov použili dva rôzne prístupy na extrakciu príznakov – Local Binary Patterns (LBP) a Histogram of Oriented Gradients (HOG). Testovali vplyv šumu na klasifikátory trénované na čistých aj zašumených dátach, pričom výsledky ukázali, že modely trénované na čistých dátach majú problém s generalizáciou na zašumených dátach. Tento efekt bol najvýraznejší pri Gaussovom šume a Salt & Pepper šume, na čo poukazuje aj ostatná literatúra. Tieto konkrétne druhy šumu výrazne ovplyvňovali výkon klasifikačných modelov.

Dôležitým zistením bolo, že aj keď metódy na odšumenie obrazu (napr. Non-Local Means, Median Filter) dokážu mierne zlepšiť výkon klasifikácie na zašumených dátach, nikdy nedosiahnu rovnakú úroveň presnosti ako modely trénované na čistých dátach. Tieto výsledky potvrdzujú, že integrácia zašumených dát do tréningového procesu môže byť efektívnejším riešením než pokusy o odstránenie šumu po získaní obrazových dát.

Tieto štúdie zdôrazňujú dôležitosť systematického začlenenia šumu do tréningového procesu neurónových sietí s cieľom zvýšiť ich robustnosť a schopnosť prispôsobiť sa reálnym podmienkam. Výskum tiež naznačuje, že kombinácia rôznych typov šumu a sofistikovaných metód predspracovania dát môže viesť k optimalizovaným stratégiám tréningu, ktoré zlepšujú generalizáciu modelov a zabezpečujú vyššiu presnosť aj pri zhoršených vstupných podmienkach. Okrem toho sa ukazuje, že metódy ako dynamické zmeny šumu počas tréningu môžu ďalej posilniť odolnosť modelov voči neočakávaným vstupným perturbačným vplyvom. Na základe týchto poznatkov sa v ďalších častiach tejto práce zameriame na návrh efektívnych metód integrácie šumu do procesu tréningu neurónových sietí, pričom budeme skúmať aj ich vplyv na rôzne architektúry modelov a úrovne zložitosti dátových vstupov.

III. NAVRHOVANÝ PRÍSTUP

Náš navrhovaný prístup k zvýšeniu robustnosti konvolučných neurónových sietí (CNN) spočíva v systematickom zavádzaní šumu do tréningových dát. Cieľom je prinútiť model učiť sa rozpoznávať relevantné črty aj v prítomnosti rôznych typov obrazového šumu, čím sa zlepší jeho schopnosť generalizovať na reálne, zašumené dáta.

A. Dataset a predspracovanie dát

Naše experimenty sme vykonávali na datasete *Oxford-IIIT Pet* z knižnice `torchvision.datasets`. Tento dataset obsahuje obrázky 37 rôznych plemien psov a mačiek. Pre načítanie a spracovanie dát bol vytvorený vlastný dátový loader, ktorý organizuje dáta podľa plemien a zabezpečuje rozdelenie na tréningovú (80%), validačnú (10%) a testovaciu

(10%) množinu s fixným `random_state=42` pre reprodukovateľnosť.

Pred spracovaním modelom boli na obrázky aplikované štandardné transformácie a augmentácie. Tieto zahŕňajú:

- Zmenu veľkosti obrázkov na 224x224 pixelov.
- Konverziu obrázkov na PyTorch tensors.
- Normalizáciu pixelových hodnôt s priemerom 0,5 a smerodajnou odchýlkou (σ) 0,5, čím sa hodnoty škálujú do rozsahu [-1; 1].

Pre tréningové dáta (nie pre validačné a testovacie) boli dodatočne aplikované augmentácie na zvýšenie variability dát a zlepšenie generalizácie:

- náhodné horizontálne otočenie,
- náhodná rotácia obrázka o 15 stupňov,
- náhodná zmena jasu, kontrastu, saturácie a odtieňa
- náhodné orezanie a zmena veľkosti obrázka.

B. Architektúra modelu

Ako základ pre našu prácu sme zvolili predtrénovaný model *ResNet34* [7], využitím techniky preneseného učenia. Architektúra *ResNet34* je široko používaná a známa svojou schopnosťou efektívne spracovávať obrazové dáta vďaka svojej štruktúre so skip-prepojeniami, ktoré pomáhajú predchádzať problému miznúcich gradientov.

Pre účely klasifikácie plemien zvierat na datase *Oxford-IIIT Pet*, ktorý obsahuje 37 odlišných tried, bolo potrebné modifikovať poslednú plne prepojenú vrstvu modelu. Pôvodná výstupná vrstva pre 1000 tried bola nahradená novou vrstvou s 37 výstupnými neurónmi, čo zodpovedá počtu klasifikačných tried v našej úlohe. Navyše, do tejto novej vrstvy bol pridaný *Dropout* s pravdepodobnosťou 0,5. *Dropout* je regularizačná technika, ktorá náhodne "vypína" neuróny počas tréningu, čím bráni prílišnej závislosti modelu na konkrétnych neurónoch a znižuje riziko pretrénovania. Vizualizácia upravenej architektúry je znázornená na Obrázku 1.

C. Aplikácia šumu

V našej implementácii sme pridávali tieto tri rôzne typy šumu a to nasledovne:

- *Gaussov šum*: Simuluje náhodné fluktuácie signálu s normálnym rozdelením. Aplikuje sa pripočítaním náhodného šumu s daným priemerom (μ) a štandardnou odchýlkou (σ).

$$\text{Obr}_{\text{zašum}} = \text{Obr}_{\text{pôvod}} + (\text{náhodnýTensorVeľkostiObr} \times \sigma + \mu)$$

V našej implementácii sme pracovali s tensorom s priemerom $\mu = 0$.

- *Poissonov šum*: Modeluje šum založený na štatistike počtu fotónov. Vychádza z Poissonovho rozdelenia, kde intenzita šumu závisí od hodnoty pixelu. Pre správnu aplikáciu na naše normalizované dáta v rozsahu [-1, 1] bola implementovaná konverzia na rozsah [0, 1], aplikácia

šumu s parametrom λ a následná konverzia späť na [-1, 1]. Matematický zápis použitý v implementácii je (s uvažovaním preškálovania):

$$\text{Obr}_{\text{zašum}} = \left(\text{Pois} \left(\left(\frac{\text{Obr}_{\text{pôvod}}}{2} + 1 \right) \times \lambda \right) \div \lambda \right) \times 2 - 1$$

- *Salt-and-pepper šum*: Simuluje chyby v digitálnom prenose alebo chyby senzora, kedy sa náhodné pixely nastavujú na minimálnu (čierna, -1 po normalizácii) alebo maximálnu (biela, 1 po normalizácii) hodnotu. Intenzita šumu je daná parametrom `amount`, ktorý určuje podiel pixelov, ktoré budú ovplyvnené. Tieto pixely sú následne rovnomerne rozdelené na pixely soli (biele) a pixely pepu (čierne). Matematický zápis použitý v implementácii:

$$\text{Obr}_{\text{zašum}} = (\text{Obr}_{\text{pôvod}} \times (1 - M_{\text{sól}}) + 1 \times M_{\text{sól}}) \times (1 - M_{\text{peper}})$$

Kde $M_{\text{sól}}$ a M_{peper} sú binárne masky tej istej veľkosti ako obrázky, kde 1 znamená aplikáciu soli resp. pepu a 0 znamená ponechanie pôvodnej hodnoty pixelu. Množstvo pixelov postihnutých šumom je rozdelené na polovicu pre každý typ:

$$\Sigma \text{pixel}_{\text{sól}} = \Sigma \text{pixel}_{\text{peper}} = \left\lfloor \frac{\text{amount} \times \text{výška obr.} \times \text{šírka obr.}}{2} \right\rfloor$$

Teda celkové množstvo ovplyvnených pixelov je $\approx \text{amount} \times \text{výška obrázka} \times \text{šírka obrázka}$.

Tieto šumové transformácie boli v rámci tréningu aplikované na každý obrázok s danou pravdepodobnosťou. Vo všetkých našich experimentoch bola táto pravdepodobnosť štandardne nastavená na 30%. Vizualizácia rôznych typov šumu a augmentácie obrázkov je znázornená na Obrázku 2.

IV. EXPERIMENTY

Navrhli sme sériu experimentov s cieľom preskúmať vplyv rôznych typov a intenzít šumu na proces tréningu a výslednú výkonnosť modelu, ako aj na jeho robustnosť voči zašumeným testovacím dátam. Celkovo sme trénovali modely s rôznymi konfiguráciami šumu počas tréningu a následne sme ich vyhodnotili na viacerých testovacích scenároch.

A. Experimentálne prostredie a parametre tréningu

Implementácia celého procesu tréningu a vyhodnotenia prebiehala v prostredí PyTorch [9] s využitím knižnice `torchbearer` [10] pre zjednodušenie tréningu a testovania modelov.

Tréningové dáta boli do modelu vkladané v dávkach (batchoch) veľkosti 128 obrázkov. Ako chybovú funkciu sme použili *CrossEntropyLoss* s nastavením *label smoothing* na hodnotu 0,1, čo pomáha predchádzať prehnanému sebavedomiu modelu a zlepšuje generalizáciu. Pre optimalizáciu parametrov modelu bol použitý algoritmus *Adam* s rýchlosťou učenia nastavenou na 0,001. Na zníženie vplyvu pretrénovania bola použitá aj L2 regularizácia s parametrom *weight decay* 0,0001. Pre efektívne ukončenie tréningu sme použili *Early Stopping*, monitorujúci validačnú stratu s trpezlivosťou 5 epoch, čo znamená, že tréning sa ukončí, ak sa validačná strata nezlepší v priebehu 5 po sebe idúcich epoch.




Fig. 1: Architektúra použitého modelu (upravená verzia obrázku prevzatého z literatúry [7]).




Fig. 2: Vizualizácia rôznych typov šumu a augmentácie obrázkov

B. Trénovacia stratégia: Curriculum Learning

Pri tréovaní sme využili prístup *Curriculum Learning* predstavený v článku [8]. Namiesto okamžitého vystavenia modelu komplexným zašumeným dátam, tréning prebiehal v piatich fázach, pričom v každej fáze bola použitá iná kombinácia a prítomnosť typov šumu. Toto postupné zavádzanie šumu malo za cieľ umožniť modelu najprv naučiť sa základné črty z čistých dát a postupne sa adaptovať na zložitejšie zašumené vstupy. Nastavenie jednotlivých fáz curriculum learningu je detailne popísané v Tabuľke 1.

TABLE I: Nastavenie fáz tréovania pomocou metódy curriculum learningu.

Epochy	Použitý Gaussov šum	Použitý Poissonov šum	Použitý salt-and-pepper šum
0 - 60	Nie	Nie	Nie
61 - 100	Áno	Nie	Nie
101 - 130	Nie	Áno	Nie
131 - 160	Nie	Nie	Áno
161 - 200	Áno	Áno	Áno

Pre implementáciu jednotlivých experimentov (Experiment

1 až Experiment 23), ktoré slúžili na natréovanie rôznych modelov s odlišnými konfiguráciami šumu počas celého tréningu (nie len v rámci fáz curriculum learningu), boli definované konkrétne nastavenia pre parametre šumu σ (pre Gaussov šum), λ (pre Poissonov šum) a amount (pre Salt-and-pepper šum). Tieto nastavenia sú prehľadne uvedené v Tabuľkách 2, 3, a 4. Každý riadok v týchto tabuľkách predstavuje samostatnú konfiguráciu šumu použitú pri tréningu jedného modelu.

TABLE II: Prvotný experiment bez aplikovania šumu (tréning na čistých dátach).

Číslo experimentu	Gauss - σ	Poiss - λ	S&P - % pixelov
Experiment 1	Bez šumu	Bez šumu	Bez šumu

C. Testovacie scenáre

Každý natréovaný model (výsledok tréovania pomocou curriculum learningu s konkrétnou konfiguráciou šumu z Experimentov 1-23) bol následne podrobený sérii troch odlišných testovacích scenárov. Tieto scenáre simulovali rôzne podmienky reálneho sveta, kde sa modely môžu stretnúť s rôznymi

TABLE III: Experimenty so zvyšujúcou sa intenzitou všetkého šumu (všetky 3 parametre použité spoločne).

Číslo experimentu	Gauss - σ	Poiss - λ	S&P - % pixelov
Experiment 2	0,01	100	0,5
Experiment 3	0,02	90	1
Experiment 4	0,03	80	2
Experiment 5	0,04	70	2,5
Experiment 6	0,05	60	3
Experiment 7	0,06	50	3,5
Experiment 8	0,08	40	4
Experiment 9	0,1	30	4,5
Experiment 10	0,2	20	5
Experiment 11	0,3	10	8

TABLE IV: Experimenty s rôznymi kombináciami intenzity šumu.

Číslo experimentu	Gauss - σ	Poiss - λ	S&P - % pixelov
Experiment 12	0,05	100	0,05
Experiment 13	0,01	50	0,05
Experiment 14	0,01	100	0,5
Experiment 15	0,1	100	0,05
Experiment 16	0,01	10	0,05
Experiment 17	0,01	100	5
Experiment 18	0,1	50	0,5
Experiment 19	0,05	10	0,5
Experiment 20	0,05	50	5
Experiment 21	0,1	10	0,05
Experiment 22	0,1	100	5
Experiment 23	0,01	10	5

typmi a intenzitami šumu na vstupných dátach. Testy boli vykonané na vyhradenej testovacej množine dát. Konfigurácia šumu aplikovaného na testovacie dáta pre každý scenár je popísaná v Tabuľke 5.

Je dôležité poznamenať, že šum v testovacích scenároch bol aplikovaný na testovacie dáta *nezávisle* od šumu použitého počas tréningu modelu. Týmto prístupom sme mohli preskúmať, ako tréning s konkrétnym typom/intenzitou šumu ovplyvní schopnosť modelu správne klasifikovať obrázky s rôznymi typmi/intenzitami šumu v testovacom prostredí.

Výkonnosť modelov v týchto testoch bola hodnotená pomocou dvoch hlavných metrík: klasifikačná presnosť (*Accuracy*) a *Makro F1 skóre*, ktoré poskytuje vyvážené hodnotenie Precision a Recall naprieč všetkými triedami, obzvlášť dôležité pre viactriedne klasifikačné úlohy s možným nevyvážením tried. Výsledky týchto testov sú prezentované a analyzované v nasledujúcej kapitole.

V. VÝSLEDKY

Po natrénovaní modelov s rôznymi konfiguráciami šumu počas tréningu, tak ako bolo popísané v Kapitole IV, boli všetky modely podrobené sérii testov na vyhradenej testovacej množine dát s rôznymi typmi a intenzitami šumu. Cieľom bolo kvantifikovať, ako tréning so šumom ovplyvní výkonnosť modelu nielen na čistých dátach, ale predovšetkým na dátach postihnutých šumom. Hodnotenie prebiehalo s použitím metrík klasifikačnej správnosti (*Accuracy*) a *Makro F1 skóre*.

Výsledky experimentov, zoradené podľa konfiguračného čísla experimentu použitého pri tréningu modelu a typu testovacej sady, sú prehľadne uvedené v Tabuľkách 6 a 7. Tieto tabuľky ukazujú dosiahnutú presnosť (*Accuracy*) a *Makro F1*

skóre pre každý model pri testovaní na troch definovaných testovacích scenároch, vrátane čistej sady a dvoch sád s kombinovaným šumom s rôznou intenzitou (silná a slabá intenzita).

A. Analýza výsledkov

Z predložených výsledkov v Tabuľkách 6 a 7 je možné vyvodiť niekoľko dôležitých pozorovaní:

- Model trénovaný na čistých dátach (Model z experimentu 1) dosiahol najvyššiu prenosť a F1 skóre na čistej testovacej sade (81,35% presnosť). Je však zrejmé, že jeho výkon drasticky klesá pri testovaní na dátach so "silným" kombinovaným šumom (57,97% presnosť), a mierne klesá aj pri "slabom" šume (69,46% presnosť). To potvrdzuje predpoklad, že modely trénované výhradne na čistých dátach nie sú robustné voči zašumeným vstupom.
- Modely trénované so šumom (Experiment 2 až Experiment 23) vo všeobecnosti vykazujú lepšiu odolnosť voči zašumeným testovacím sadám v porovnaní s modelom trénovaným bez šumu. Ich výkon na čistých testovacích dátach môže byť o niečo nižší ako pri základnom modeli, ale rozdiel je často menší ako zlepšenie na zašumených sadách.
- Intenzita šumu počas tréningu má významný vplyv na robustnosť. V Tabuľke VI (Experimenty 2–11), kde sa intenzita šumu postupne zvyšuje, môžeme sledovať, ako vyššie intenzity šumu pri tréningu (Experiment 10, Experiment 11) vedú k lepšej presnosti na zašumených testovacích sadách ("Všetky šumy - silné", "Všetky šumy - slabé") v porovnaní s modelmi trénovanými s nižšou intenzitou šumu (Experiment 2, Experiment 3 atď.). Zároveň však môže príliš vysoká intenzita šumu pri tréningu mierne znížiť výkon na čistých dátach (napr. porovnajme presnosť na teste "Bez šumu" pre Experiment 1 a Experiment 11).
- Rôzne kombinácie intenzít šumov (Tabuľka 7) tiež ukazujú rôzne výsledky v závislosti od použitých intenzít. Niektoré kombinácie šumu a ich intenzity (Experiment 17, Experiment 18, Experiment 22) dosiahli veľmi dobrú presnosť na "slabo" zašumených testovacích sadách, dokonca sa približujú alebo prekonávajú presnosť základného modelu na čistých dátach, a zároveň si udržali výrazne vyššiu presnosť na "silne" zašumených sadách. Napríklad, Model z Exp. 17 dosiahol 81,22% presnosť na "Všetky šumy - slabé", čo je porovnateľné so základným modelom na čistých dátach (81,35%).
- Curriculum learning použitý v tréningovom procese by mal teoreticky kombinovať výhody tréningu na čistých dátach (získanie základných črt) s postupným zavádzaním šumu (zvýšenie robustnosti). Výsledok testu na čistých dátach po curriculum learningu 77,04% ukazuje, že zameranie na robustnosť voči šumu mierne znížilo výkon na čistých dátach, čo je očakávaný kompromis.)

Detailná analýza jednotlivých experimentov a ich výsledkov umožňuje identifikovať optimálne stratégie tréningu so zašumenými dátami pre konkrétnu úlohu a očakávané

TABLE V: Vysvetlenie 3 testov, ktorým boli podrobené všetky natréňované modely.

Test	Použitý Gauss	Použitý Poiss	Použitý S&P	Gauss - σ	Poiss - λ	S&P - % pixelov
Bez šumu	Nie	Nie	Nie	—	—	—
Všetky šumy - silné	Áno	Áno	Áno	0,1	10	5
Všetky šumy - slabé	Áno	Áno	Áno	0,01	100	0,5

TABLE VI: Výsledky experimentov so zvyšujúcou sa intenzitou pridávania šumu do obrázkov (1. časť experimentov).

Natréňovaný model	Testovacia sada	Presnosť [%]	Makro F1 [%]
Model z Exp. 1	Bez šumu	81,35	81,16
	Všetky šumy - silné	57,97	63,49
	Všetky šumy - slabé	69,46	70,24
Model z Exp. 2	Bez šumu	77,7	77,94
	Všetky šumy - silné	63,92	65,22
	Všetky šumy - slabé	78,78	78,71
Model z Exp. 3	Bez šumu	79,32	79,15
	Všetky šumy - silné	61,49	62,44
	Všetky šumy - slabé	78,24	77,97
Model z Exp. 4	Bez šumu	78,92	78,84
	Všetky šumy - silné	67,3	68,27
	Všetky šumy - slabé	80,54	80,37
Model z Exp. 5	Bez šumu	72,03	72,45
	Všetky šumy - silné	62,57	63,84
	Všetky šumy - slabé	72,3	72,88
Model z Exp. 6	Bez šumu	76,35	77,35
	Všetky šumy - silné	68,38	69,45
	Všetky šumy - slabé	75,54	76,41
Model z Exp. 7	Bez šumu	79,19	79,06
	Všetky šumy - silné	72,43	72,31
	Všetky šumy - slabé	78,24	78,14
Model z Exp. 8	Bez šumu	75,27	75,1
	Všetky šumy - silné	70,27	69,67
	Všetky šumy - slabé	73,51	73,08
Model z Exp. 9	Bez šumu	78,11	78,1
	Všetky šumy - silné	65,95	66,69
	Všetky šumy - slabé	73,78	73,92
Model z Exp. 10	Bez šumu	78,51	78,18
	Všetky šumy - silné	71,35	70,99
	Všetky šumy - slabé	77,7	77,46
Model z Exp. 11	Bez šumu	77,7	77,72
	Všetky šumy - silné	75,14	75,0
	Všetky šumy - slabé	78,11	78,05

charakteristiky vstupných dát v reálnom nasadení. Výsledky naznačujú, že mierna až stredná intenzita šumu pri tréningu a vhodné kombinácie šumov môžu viesť k modelom s lepšou rovnováhou medzi presnosťou na čistých dátach a robustnosťou voči zašumeným dátam.

VI. ZÁVER

V tejto práci sme sa úspešne venovali výskumu a implementácii prístupov na zvýšenie robustnosti konvolučných neurónových sietí voči obrazovému šumu prostredníctvom modifikácie tréningového procesu. Použitím preneseného učenia s modelom ResNet34 a datasetom Oxford-IIIT Pet sme demonštrovali, že zavedenie Gaussovho, Poissonovho a Salt-and-pepper šumu do tréningových dát významne ovplyvňuje schopnosť modelu vysporiadať sa so zašumenými vstupmi počas inferencie. Naše experimenty potvrdili, že model tréňovaný výhradne na čistých dátach, hoci dosahuje najvyšší výkon na rovnako čistých testovacích dátach, je vysoko citlivý na prítomnosť akéhokoľvek typu a intenzity šumu. Naopak, modely tréňované s pridaním šumu preukázali výrazne vyššiu

TABLE VII: Výsledky experimentov s kombinovanými intenzitami šumu (2. časť experimentov).

Natréňovaný model	Testovacia sada	Presnosť [%]	Makro F1 [%]
Model z Exp. 12	Bez šumu	77,16	76,57
	Všetky šumy - silné	58,92	61,24
	Všetky šumy - slabé	75,81	75,24
Model z Exp. 13	Bez šumu	77,16	76,78
	Všetky šumy - silné	61,22	64,49
	Všetky šumy - slabé	74,73	74,62
Model z Exp. 14	Bez šumu	76,76	77,05
	Všetky šumy - silné	64,59	66,55
	Všetky šumy - slabé	76,35	76,71
Model z Exp. 15	Bez šumu	78,11	78,1
	Všetky šumy - silné	65,95	66,69
	Všetky šumy - slabé	73,78	73,92
Model z Exp. 16	Bez šumu	77,03	76,8
	Všetky šumy - silné	68,24	68,25
	Všetky šumy - slabé	76,89	76,6
Model z Exp. 17	Bez šumu	80,54	80,57
	Všetky šumy - silné	65,95	66,86
	Všetky šumy - slabé	81,22	81,21
Model z Exp. 18	Bez šumu	80,27	80,18
	Všetky šumy - silné	70,14	70,87
	Všetky šumy - slabé	79,32	79,23
Model z Exp. 19	Bez šumu	76,22	76,59
	Všetky šumy - silné	73,51	73,57
	Všetky šumy - slabé	76,62	76,83
Model z Exp. 20	Bez šumu	79,32	79,23
	Všetky šumy - silné	73,92	74,16
	Všetky šumy - slabé	77,57	77,56
Model z Exp. 21	Bez šumu	78,65	78,33
	Všetky šumy - silné	71,22	70,97
	Všetky šumy - slabé	77,43	76,88
Model z Exp. 22	Bez šumu	77,7	77,72
	Všetky šumy - silné	66,35	66,27
	Všetky šumy - slabé	78,11	77,93
Model z Exp. 23	Bez šumu	77,57	77,57
	Všetky šumy - silné	75,68	75,41
	Všetky šumy - slabé	77,7	77,81

odolnosť voči zašumeným testovacím sadám, čo je kľúčové pre ich nasadenie v reálnych aplikáciách, kde je kvalita vstupných dát často suboptimálna. Analýza výsledkov z rozsiahlej sady experimentov s rôznymi intenzitami a kombináciami šumu pri tréningu odhalila, že neexistuje univerzálne optimálne nastavenie šumu. Mierna až stredná intenzita šumu počas tréningu, ako napríklad v Experimentoch 4, 7, 10 (postupné zvyšovanie intenzity), či niektoré špecifické kombinácie šumov v Experimentoch 17, 18 a 22, viedli k modelom s najlepším kompromisom medzi zachovaním výkonnosti na čistých dátach a zvýšenou presnosťou a F1 skóre na zašumených testovacích sadách, obzvlášť pri miernej intenzite šumu. Príliš agresívne zavedenie šumu síce zvyšuje robustnosť voči silnému šumu, ale môže viesť k nezanedbateľnému poklesu presnosti na čistých dátach. Použitie stratégie Curriculum Learning, kde sa šum zavádzal postupne v tréningových fázach, je sľubným prístupom, ktorý si vyžaduje ďalší výskum v oblasti optimalizácie trvania jednotlivých fáz a konfigurácie šumu v

nich. Napriek tomu, model trénovaný s curriculum learningom dosiahol na čistých testovacích dátach prijateľnú presnosť (77,04%), ktorá je síce nižšia ako pri základnom čistom modeli, ale očakáva sa od neho lepšia generalizácia a robustnosť voči šumu. Celkovo naša práca potvrdzuje významnosť tréningu so zašumenými dátami ako efektívny prístup pre tréning CNN. Identifikácia optimálnych parametrov a stratégií aplikácie šumu je dôležitým krokom k vývoju spoľahlivejších modelov počítačového videnia pre variabilné reálne podmienky. Budúci výskum by sa mohol zamerať na dynamickú adaptáciu parametrov šumu počas tréningu na základe validačného výkonu modelu, preskúvanie vplyvu šumu na hlbšie a novšie architektúry sietí ako napr. transformerové modely alebo analýzu vplyvu šumu na iné úlohy počítačového videnia ako napr. detekcia objektov či segmentácia.

REFERENCES

- [1] tejasheeganesan. (2024). "Train Neural Networks With Noise to Reduce Overfitting". [online]. [cit 2025-03-03]. Dostupné na internete: <https://www.geeksforgeeks.org/train-neural-networks-with-noise-to-reduce-overfitting/>.
- [2] Nazaré, T.S., da Costa, G.B.P., Contato, W.A., Ponti, M. (2018). "Deep Convolutional Neural Networks and Noisy Images". In: *Mendoza, M., Velastín, S. (eds) Progress in Pattern Recognition, Image Analysis, Computer Vision, and Applications. CIARP 2017. Lecture Notes in Computer Science()*, vol 10657. str. 416-424 [online]. Springer, Cham. [cit 2025-03-03]. ISBN: 978-3-030-68779-3. DOI: https://doi.org/10.1007/978-3-319-75193-1_50.
- [3] Rodríguez-Rodríguez J.A., Molina-Cabello M.A., Benítez-Rochel R., López-Rubio E. (2021). "The Effect of Noise and Brightness on Convolutional Deep Neural Networks". In: *Del Bimbo, A., et al. Pattern Recognition. ICPR International Workshops and Challenges. ICPR 2021. Lecture Notes in Computer Science()*, vol 12666. str. 639-654 [online]. Springer, Cham. [cit 2025-03-03]. ISBN: 978-3-030-68779-3. DOI: https://doi.org/10.1007/978-3-030-68780-9_49.
- [4] Omkar M. Parkhi, Andrea Vedaldi, Andrew Zisserman, C. V. Jawahar. (2012). "Cats and Dogs". In: *IEEE Conference on Computer Vision and Pattern Recognition 2012*. [online]. IEEE. Dostupné na internete: <https://www.robots.ox.ac.uk/~vgg/publications/2012/parkhi12a/parkhi12a.pdf>. Dataset: <https://www.robots.ox.ac.uk/~vgg/data/pets/>
- [5] Dodge S., Karam L. (2016). "Understanding How Image Quality Affects Deep Neural Networks". In: *Proceedings of the Conference on the Quality of Multimedia Experience (QoMEX)* [online.] IEEE. [cit 2025-03-05]. e-ISBN: 978-1-5090-0354-9. DOI: 10.1109/QoMEX.2016.7498955.
- [6] Gabriel B. Paranhos da Costa, Welinton A. Contato, Tiago S. Nazare, João E. S. Batista Neto, Moacir Ponti. (2016). "An empirical study on the effects of different types of noise in image classification tasks". [online]. arXiv preprint. [cit 2025-03-05]. DOI: <https://doi.org/10.48550/arXiv.1609.02781>.
- [7] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun. (2015). "Deep Residual Learning for Image Recognition". [online]. arXiv preprint. [cit 2025-05-08]. DOI: <https://doi.org/10.48550/arXiv.1512.03385>.
- [8] Bengio Y., Louradour Jérôme, Collobert Ronan, Weston Jason. (2009). "Curriculum learning". In: *Journal of the American Podiatry Association*. vol. 60. [online]. Research Gate. [cit. 2025-05-09]. DOI: 10.1145/1553374.1553380. Dostupné na internete: https://www.researchgate.net/publication/221344862_Curriculum_learning.
- [9] Paszke Adam, Gross Simon, Massa Francesco, Lerer Adam, Bradbury James, Chanan Guy, Killeen Tyler, Lin Zeming, Gimelshein Nikhil, Antiga Luca a kol. (2019). "PyTorch: An Imperative Style, High-Performance Deep Learning Library". [online]. arXiv preprint. [cit. 2025-05-09]. DOI: <https://doi.org/10.48550/arXiv.1912.01703>.
- [10] Harris Ethan, Painter Matthew, Hare Jonathon. (2018). "Torchbearer: A Model Fitting Library for PyTorch". [online]. arXiv preprint. [cit. 2025-05-09]. DOI: <https://doi.org/10.48550/arXiv.1809.03363>.
- [11] Y. LeCun, L. Bottou, Y. Bengio, P. Haffner. (1989). "Backpropagation Applied to Handwritten Zip Code Recognition". In: *Neural Computation*, zv. 1, č. 4, s. 541-551, Dec. 1989. DOI: 10.1162/neco.1989.1.4.541. ISSN: 0899-7667. Dostupné na internete: <https://ieeexplore.ieee.org/document/6795724>.
- [12] Bishop C. M., a kol. (1995). "Training with Noise is Equivalent to Tikhonov Regularization". In: *Neural Computation*, zv. 7, č. 1, s. 108-116, Jan. 1995. [online]. MIT Press. [cit. 2025-05-09]. DOI: 10.1162/neco.1995.7.1.108. ISSN: 0899-7667.